

Do relato clínico ao grafo de conhecimento

Extração de sintomas, exames, condições e tratamentos dos relatos do MultiCaRe — com reconstrução parcial da ordem dos acontecimentos.

EQUIPE

Fernando Penido - 281180

Gabriel Antunes - 281199


Gabriel Schade - 281202

Henrique Silveira - 239212

Lucas Boaro - 281303

DEMONSTRAÇÃO · CÓDIGO

lucasboaro.github.io/MC896---NLP/ · github.com/lucasBoaro/MC896---NLP



A informação está no texto corrido


PMC5137649_01 · CASE_TEXT (TRECHO)

A 44-year-old woman presented with a 3-day history of right flank and lower quadrant **abdominal pain** associated with **nausea** and **constipation**. [...] She underwent contrast enhanced **computed tomography** [...] **FNA** of the cyst demonstrated *no evidence of malignancy* but did show [...] suggesting the diagnosis of a **mucinous pancreatic cystic neoplasm**.

CÓDIGO DE CORES USADO EM TODA A APRESENTAÇÃO

● Sintoma ● Exame ● Condição ● Tratamento

O GRAFO CORRESPONDENTE



Objetivo

Extrair sintomas, exames, condições e tratamentos, conectá-los em um grafo e guardar a frase que originou cada extração.

Pergunta adicional

É possível reconstruir parte da sequência temporal do caso?

O formato do grafo: os nós



Vem direto do CSV

É o único nó que não precisa ser procurado no texto. Organiza todas as extrações de um relato e guarda os metadados do artigo.

`article_id` · `age` · `gender` · `title`



Symptom

122 nós

Sintoma ou sinal apresentado pelo paciente.

`fever` · `abdominal pain` · `dyspnea`



Exam

281 nós

Exame ou método diagnóstico.

`CT scan` · `biopsy` · `endoscopy`



Condition

212 nós

Doença, diagnóstico ou achado clínico.

`pneumonia` · `SLE` · `COVID-19`



Treatment

213 nós

Medicamento, procedimento ou terapia.


`prednisone` · `surgical resection`

Cada nó é uma ocorrência, não um conceito. Duas tomografias em dias diferentes geram dois nós com o mesmo rótulo canônico — normalizar o nome não pode apagar a cronologia.

O formato do grafo: as relações


Organização — ligam o caso às entidades

Criadas por um gatilho de relação compatível com o tipo da entidade.



Clínicas e temporal — entre entidades

Exigem gatilho específico no escopo da oração e tipos compatíveis.



BEFORE é a única direção temporal: AFTER seria redundante.

Proximidade não basta. INDICATES, TREATS e BEFORE nunca são criadas só porque duas entidades aparecem na mesma frase: é preciso um gatilho compatível dentro do escopo.

Quatro recursos com funções complementares

1

Léxico

reconhece a entidade

shortness of breath

→ Symptom / dyspnea

CT scan → Exam

2

Gatilhos

interpretam o contexto

diagnosed with

→ DIAGNOSED_WITH

no evidence of → NEGATED

3

Regex

capturam valores variáveis

500 mg · 180 mg/dL

two days after admission

12 March 2020

4

Regras

decidem se vira um fato

escopo da oração

negação · incerteza

proximidade · compatibilidade

A REGRA EM AÇÃO · PMC5137649_01

```
# o alcance da negação termina na pontuação forte...
blocked = any(m in between for m in ".;:")
# ...e nos conectivos adversativos
blocked = blocked or re.search(r"\b(?:but|however)\b", between)

if distance <= max_distance and not blocked:
    candidates.append((distance, trigger))
```

"[...] demonstrated **no evidence of malignancy** **but** did show [...] **suggesting the diagnosis of** a mucinous pancreatic cystic neoplasm."

malignancy descartada pela negação

fine-needle aspiration —INDICATES► **neoplasm**

Representar a ordem dos acontecimentos



O extrator utiliza offsets para localizar entidades e expressões no texto, calcular proximidade e auxiliar na associação entre elas. Entretanto, a distância por offsets não é suficiente sozinha: também são considerados a frase, o tipo das entidades, os gatilhos e as regras específicas de cada relação.



- expressões temporais são reconhecidas por regex e gatilhos;
- offsets e referências ficam nos atributos dos nós;
- a ordem confirmada gera uma aresta BEFORE;
- não criamos nós de tempo nem a relação redundante AFTER;
- referência ambígua: a expressão é preservada sem inventar uma data.

"Four days later, a repeat CT showed a small amount of extraluminal air abutting the stent."

stent placement —BEFORE→ repeat CT

Eventos com informações temporais mas ordem não identificada

Sequência de eventos

Ordem temporal parcial baseada somente em expressões de tempo e relações BEFORE.

Importante: a ordem em que uma informação aparece no texto não implica que ela tenha ocorrido antes ou depois de outra.

a two-week history

petechiae

An 81-year-old female was admitted to an internal medicine (IM) department with a two-week history of petechial rash over her upper and lower extremities.

SINTOMA

During hospitalization

deep vein thrombosis

During hospitalization the patient developed a deep vein thrombosis and treatment with low molecular weight heparin (LMWH) was initiated.

CONDIÇÃO

During hospitalization

low molecular weight heparin

During hospitalization the patient developed a deep vein thrombosis and treatment with low molecular weight heparin (LMWH) was initiated.

TRATAMENTO

for 10 days

triple therapy

The patient was treated for 10 days with a triple-therapy regime consisting of omeprazole, amoxicillin, and clarithromycin.

TRATAMENTO

for 10 days

omeprazole

The patient was treated for 10 days with a triple-therapy regime consisting of omeprazole, amoxicillin, and clarithromycin.

TRATAMENTO

for 10 days

amoxicillin

The patient was treated for 10 days with a triple-therapy regime consisting of omeprazole, amoxicillin, and clarithromycin.

TRATAMENTO

for 10 days

clarithromycin

The patient was treated for 10 days with a triple-therapy regime consisting of omeprazole, amoxicillin, and clarithromycin.

TRATAMENTO

☐ Também mostrar eventos sem posição temporal

7 / 17

A V1 foi construída só com 45 casos

45 casos de desenvolvimento 80% dos artigos · construção do léxico, dos gatilhos e das regras

11 casos
20% · reservados

● Divisão por artigo

Todos os casos de um mesmo artigo ficaram no mesmo grupo. Isso evita que vocabulário e estilo de um artigo vazem de um grupo para o outro.

● Divisão reproduzível

A semente fixa 42 faz `prepare_data.py` gerar sempre os mesmos 45 e 11 casos, em `development.csv` e `evaluation.csv`.

● Metadados como candidatos

Título, keywords e MeSH terms dos artigos serviram de fonte de termos — mas nenhum vira nó sem aparecer no `case_text`.

● Avaliação intocada

Os 11 casos não foram consultados durante a construção da V1, para observar depois como o método lida com textos novos.

`prepare_data.py` → `development.csv` (45) · `evaluation.csv` (11) · `all_cases.csv` (56, com a coluna `split`)

Como montamos o léxico, os gatilhos e as expressões regulares

● Léxico

um termo só entra se...

- representar uma entidade clínica relevante;
- pertencer claramente a um dos quatro tipos;
- aparecer no texto, ou ajudar a reconhecer uma forma presente nele;
- não ser palavra narrativa genérica (patient, history);

Sinônimos e siglas são reunidos pelo campo canonical.

● Gatilhos

uma expressão só entra se...

- indicar claramente relação, negação, incerteza ou referência temporal;
- tiver utilidade além de uma frase isolada;
- reduzir relações criadas apenas por coocorrência.

Categorias: relações · alvo de tratamento · negação · incerteza · resolução · não realizado · âncoras temporais.

● Expressões regulares

quando usar

- a estrutura é estável, mas os valores mudam;
- enumerar todos os casos num CSV não faria sentido.


500 mg · 1.5 g

180 mg/dL · 38.5 °C

12 March 2020

three days after
admission

O CICLO INCREMENTAL, SÓ NOS 45 CASOS DE DESENVOLVIMENTO



O fluxo implementado



EXECUÇÃO

```
python -m src.build_graph
```

```
python -m src.visualize_graph
```

Coerente, mas com pouca cobertura

95

entidades
extraídas

99

arestas
no total

4

relações entre
entidades

0

relações
TREATS

1

caso sem
nenhuma entidade

Diagnósticos centrais não reconhecidos

Behçet disease doença de Behçet

appendicitis apendicite

tracheoesophageal fistula fístula traqueoesofágica

TTP púrpura trombocitopênica trombótica

neonatal compartment syndrome síndrome compartimental neonatal

O principal gargalo observado era a cobertura lexical.

As extrações inspecionadas eram, em geral, coerentes. O extrator funcionava quando o termo estava no léxico, mas não reconhecia vários conceitos novos.

A análise indicou que ampliar o léxico e os gatilhos era o próximo passo mais útil.

Nenhum ID inválido, nenhuma relação entre casos diferentes e nenhum loop foram encontrados: a estrutura do grafo estava consistente desde a V1.

O que mudou na V2 — e o que não mudou

AMPLIAMOS

Léxico: 231 → 376 termos

Revisão das entidades centrais que a V1 não reconheceu, com novos sinônimos e abreviações.

Gatilhos: 89 → 118 expressões

Novas formas de expressar resultado de exame e início de tratamento.

Formas canônicas

Behçet disease, TTP e hydroxychloroquine-induced cardiomyopathy passaram a ser reconhecidas.

Origem registrada

Cada termo registra sua origem em source: case_text na V1 e evaluation_v2 nas ampliações feitas após a análise dos 11 casos.



MANTIVEMOS INTACTO

A lógica principal do extrator

Nenhuma regra de escopo, negação ou relação foi reescrita entre as duas versões.

O esquema do grafo

Os mesmos 5 tipos de nó e 7 tipos de aresta.

A V1 inteira


Recursos e saídas da V1 continuam no repositório, em resources/v1 e outputs/*/v1, para permitir a comparação.

O mesmo comando

Trocar --lexicon e --triggers basta para reproduzir qualquer uma das duas versões.

A V2 é uma ampliação controlada de recursos, não um novo algoritmo. Isolar a variável é o que torna a comparação do próximo slide interpretável.

A cobertura aumentou



COBERTURA NOS 11 CASOS		
	V1	V2
Termos no léxico	231	376
Gatilhos	89	118
Sintomas	21	36
Exames	46	75
Condições	12	69
Tratamentos	17	67
INDICATES	2	12
TREATS	0	5
BEFORE	2	2
Casos sem entidade	1	0

Sem anotação-ouro, comparamos cobertura: 95 → 247 entidades e 4 → 19 relações entre entidades. O maior aumento ocorreu em condições, tratamentos, **INDICATES** e **TREATS**; **BEFORE** permaneceu em 2. Como ajustamos a V2 após observar estes casos, o resultado não representa um teste independente de generalização.




Fluxo de extração



Mitigação de erros:

- checa gatilhos como “no”, “disappearance”, “was refused”, etc
- checa proximidade e se tem quebra de contexto com ; ou “but”, “however”

Grafo final e demonstração



Limitações

● Dependência do léxico

O que não está no dicionário não existe para o extrator. Ausência de extração não significa ausência da informação no texto.

● Falsos positivos

Termos genéricos como laboratory testing ou physical examination geram nós repetidos e de baixo valor informativo.

● Escopo e tempo heurísticos

Pontuação e conectivos aproximam o alcance real da negação; a resolução temporal fica em 9 arestas BEFORE nos 56 casos.

● Sem anotação-ouro

Medimos cobertura e consistência estrutural. Precisão e recall completos exigiriam anotação manual dos casos.

A V2 foi ajustada depois de observar os 11 casos. O desempenho dela nesses mesmos casos mostra uma melhoria pós-análise, não uma avaliação independente de generalização.

O que aprendemos

Uma abordagem simples e interpretável transformou relatos clínicos em grafos auditáveis e incorporou parcialmente a temporalidade.

01

Recursos complementares

Léxico, gatilhos e expressões regulares têm responsabilidades diferentes. Manter cada recurso em seu arquivo permitiu localizar o gargalo.

02

A avaliação apontou o gargalo

O resultado da V1 mostrou que o limite era cobertura lexical, e não a lógica do extrator.

03

Comparação preservada

Manter V1 e V2 lado a lado tornou visível o processo incremental, e também os seus limites.

Continuação: validar o extrator em novos casos ainda não observados, ou comparar as regras com um método baseado em modelo.

DEMONSTRAÇÃO · CÓDIGO

lucasboaro.github.io/MC896---NLP/ · github.com/lucasBoaro/MC896---NLP