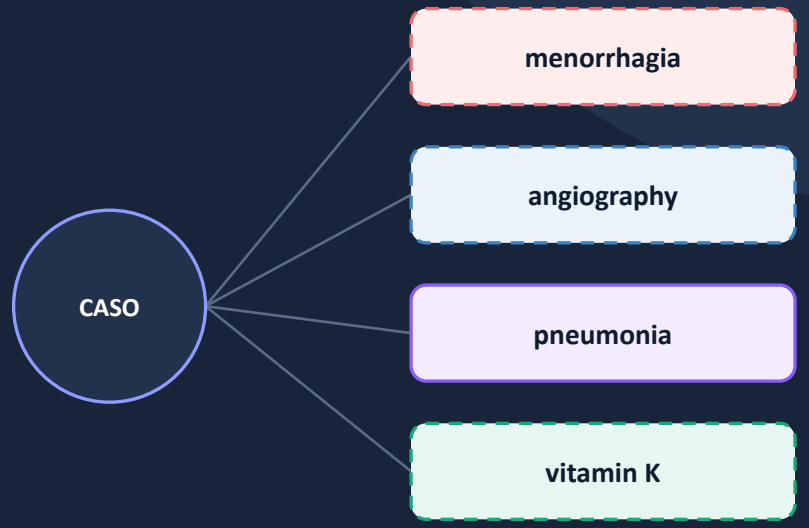
MC896 · PROCESSAMENTO DE LINGUAGEM NATURAL · PROJETO 2

O texto clínico pode ensinar o extrator?

Do léxico, dos gatilhos e das regras de tempo escritos à mão no Projeto 1 a recursos aprendidos com n-gramas, PMI, Naive Bayes e regressão logística.



borda tracejada = termo aprendido (V3)

EQUIPE
Fernando Penido - 281180
Gabriel Antunes - 281199
Henrique Silveira - 239212
Lucas Boaro - 281303

DEMONSTRAÇÃO · CÓDIGO
lucasboaro.github.io/MC896---NLP/ · github.com/lucasBoaro/MC896---NLP

Onde a parte 1 terminou

UM EXTRATOR INTERPRETÁVEL, COM RECURSOS ESCRITOS À MÃO

1. **Léxico** — reconhece a entidade
2. **Gatilhos** — interpretam o contexto
3. **Regex** — valores e tempo
4. **Regras** — decidem o fato

231 → 376
termos no léxico (V1 → V2)

95 → 247
entidades nos 11 casos

4 → 19
relações entre entidades

15%
dos eventos com posição no tempo

O problema era a cobertura, nas três frentes.

O léxico não reconhecia conceitos novos, as relações só nasciam com um gatilho escrito à mão, e a linha do tempo, nosso diferencial, só posicionava eventos com uma expressão de tempo explícita por perto. A V2 ampliou os recursos à mão, depois de ler os 11 casos de avaliação.

A CONTINUAÇÃO PROPOSTA NO PROJETO 1

"Validar o extrator em novos casos ainda não observados, ou comparar as regras com um método baseado em modelo."

A parte 2 começa aqui.

A PERGUNTA DA PARTE 2

O texto consegue ensinar o que escrevemos à mão?

FRENTE 1 · ENTIDADES

Léxico

PROJETO 1 · MANUAL

lexicon.csv escrito à mão (231 e 376 termos)

→

PROJETO 2 · APRENDIDO

Léxico V3: n-gramas + PMI + regressão logística

FRENTE 2 · RELAÇÕES

TREATS e INDICATES

PROJETO 1 · MANUAL

relação só existe com gatilho manual na frase

→

PROJETO 2 · APRENDIDO

Gatilhos por PMI e classificadores de pares

FRENTE 3 · LINHA DO TEMPO

Fase de cada evento

PROJETO 1 · MANUAL

posição só com expressão de tempo explícita

→

PROJETO 2 · APRENDIDO

Regressão logística prevê a fase do relato

✓ **build_graph.py não muda**

Só os recursos e as camadas aprendidas mudam, como na V1 → V2.

✓ **Avaliação separada**

Os 11 casos de avaliação ficam fora do treino dos modelos.

✓ **ML clássico**

Sem LLM, embeddings ou Transformers: n-gramas, PMI, regressão logística, Naive Bayes.

Como o léxico V3 é aprendido

1 45 casos de desenvolvimento → **2** n-gramas de 1 a 4 palavras por frase → **3** filtro de colocação: PMI ≥ 3 e NPMI ≥ 0,30 → **4** rótulo fraco: tipo da V1 ou NONE → **5** regressão logística ranqueia e tipa → **6** lexicon.csv V3 com 483 termos

PMI: AS PALAVRAS APARECEM JUNTAS MAIS QUE O ACASO?

$$PMI(x,y) = \log_2 \frac{P(x,y)}{P(x)P(y)}$$

$$NPMI = \frac{PMI}{-\log_2 P(x,y)}$$

Separa termos como “acute coronary syndrome” de sequências narrativas. O NPMI fica entre −1 e 1 e reduz o prêmio que o PMI dá a pares raros.

O QUE O CLASSIFICADOR VÊ

- **Letras do termo**
  `-itis · -scopy · -ectomy · -mab`
- **Palavras vizinhas**
  `treated with · underwent`
- **Estatísticas**
  `frequência · PMI · NPMI`

SUPERVISÃO FRACA

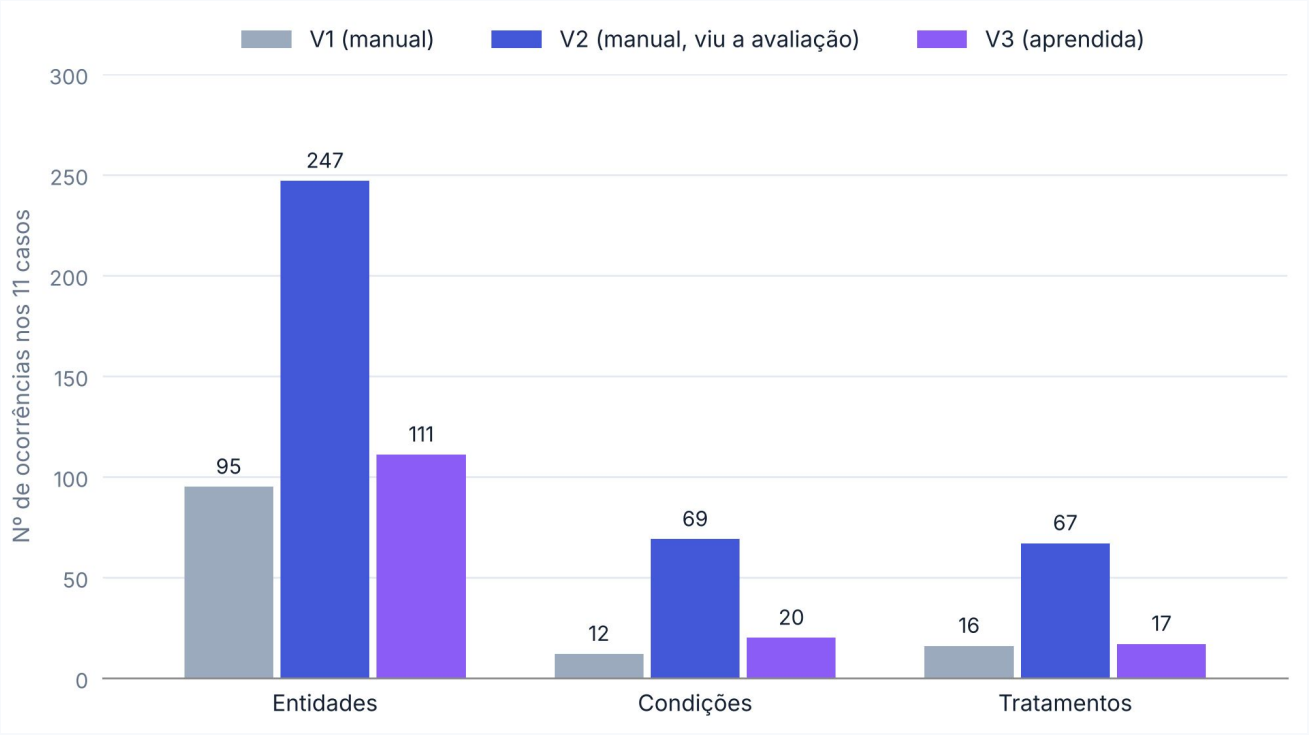
As regras da parte 1 viram professor: termo da V1 recebe o seu tipo; n-grama narrativo recebe NONE.

```
# chance de ser entidade
score = 1.0 - proba[:, none_col]
```

O que ensina o tipo são as letras do termo: sem letras e sem contexto, o tipo correto cai de 0,72 para 0,33 (10 repetições). O PMI diz se um n-grama é termo, não de que tipo ele é.

FRENTE 1 · RESULTADO NOS MESMOS 11 CASOS

A V3 aprende a forma dos termos, mas cobre pouco



CONTRA AS ENTIDADES DA V2

revocação 0,38 = V1
precisão 0,99 → 0,85

acerta: menorrhagia, lymphadenopathy, laparotomy

erra: examination, electrocardiogram ecg, endocarditis como Symptom

38 de 145

termos da V2 aparecem no texto de mineração. A V3 recupera 1.

A V3 corrige a ressalva da parte 1, pois é a primeira versão feita sem olhar os 11 casos. Mas com 45 casos o gargalo é o corpus: um termo que nunca aparece no texto não tem como ser aprendido.

O mesmo gargalo nos gatilhos de relação

97

pares candidatos

tratamento–condição ou exame–condição na mesma frase

43 · 54

TREATS · INDICATES

léxico V2, 56 casos

18 · 24

marcados pelas regras

só onde há gatilho manual

71 / 97

relações verdadeiras

rotulados à mão, um a um

DOIS CAMINHOS, SEM MUDAR O EXTRATOR

1 **Gatilhos aprendidos por PMI**

O PMI mede a correlação entre as palavras vizinhas e a real existência da relação. Palavras com alto PMI, presentes em 2 ou mais casos, são incorporadas como novos gatilhos nas regras.

2 **Classificar cada par**

Naive Bayes e regressão logística sobre as palavras entre e antes das entidades; a regressão também usa distância, ordem e o NPMI do par.

O QUE A ROTULAÇÃO REVELOU NAS REGRAS

"… was treated effectively with moxifloxacin …"

`moxifloxacin —TREATS▸ abscess  perdida`

"... of severe lupus, was admitted to the ICU and eventually treated with prednisone…"

`prednisone —TREATS▸ lupus  perdida`

Proximidade e gatilho fixo não bastam nos dois sentidos.

Regras são precisas, mas perdem 40% das relações

	INDICATES			TREATS		
Método	Prec.	Rev.	F1	Prec.	Rev.	F1
sempre sim (referência)	0,78	1,00	0,88	0,67	1,00	0,81
regras (projeto 1)	**1,00**	0,57	0,73	**0,94**	0,59	0,72
regras + gatilhos PMI	0,94	**0,69**	0,80	0,94	0,59	0,72
limiar de NPMI do par	0,78	1,00	0,88	0,67	1,00	0,81
Naive Bayes	0,77	0,95	0,85	0,81	0,86	**0,83**
regressão logística	0,78	0,93	0,85	0,63	0,76	0,69

TREATS

Naive Bayes é o único que conseguiu superar a referência no F1 score.

INDICATES

Os gatilhos aprendidos sobem a revocação das regras de 0,57 para 0,69, mantendo precisão 0,94.

NPMI DO PAR

Escolheu o menor limiar e virou “sempre sim”: coocorrer no corpus não separa relações dentro da frase.

Dois cuidados com o PMI: com 71 de 97 positivos, “sempre sim” já tira F1 alto e precisa estar na tabela;

TENTATIVA DE EVOLUÇÃO

Testando com 1000 casos a mais

Motivação

V3 só via 45 casos. Dos 145 termos da V2, só 38 aparecem nesse texto.

O Naive Bayes era o melhor método nos pares rotulados, mas só era avaliado. O grafo da V3 nos 11 casos tinha 0 TREATS e 3 INDICATES, porque havia só 7 pares candidatos.

Resultados nos 11 casos (V3 → V3+)	V3	V3+
Termos no léxico	483	942
Entidades	111	143
Condições	20	34
Tratamentos	17	33
Relações	3	11

Conclusões

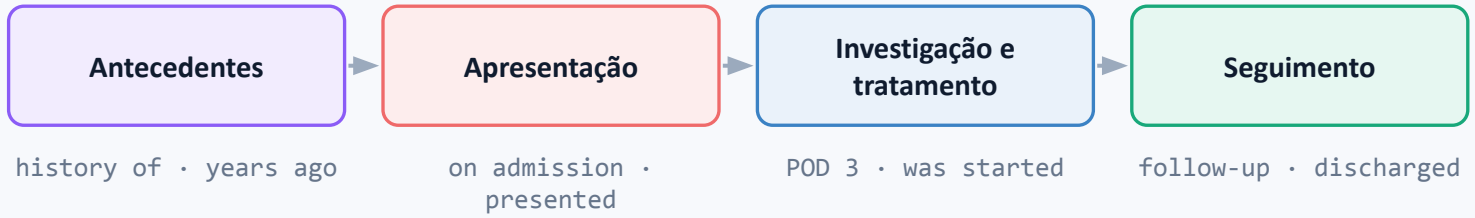
- Mais texto aumenta a cobertura, o que confirma que o gargalo era o corpus.
- O Naive Bayes ganha em revocação e perde em precisão: das 11 relações da V3+ nos 11 casos, 8 estão corretas. Um erro típico é `biopsy → kidney injury`, em que a lesão é o motivo da biópsia.O léxico maior também traz ruído, como nomes de fabricantes (`bd biosciences san jose`).

A mesma receita aplicada à linha do tempo

15%

dos 957 eventos da V3 tinham posição no tempo com as regras da parte 1, e havia só 12 arestas BEFORE nos 56 casos.

EM VEZ DE UM DIA EXATO, A FASE DO RELATO (COMO O DOCTIMEREL DO CORPUS THYME)



exemplos de expressões seguras que as regras já reconhecem em cada fase

1 Regras seguras rotulam

Regras de fase (expressões de tempo e verbos típicos) rotulam 39% dos eventos.

2 Expressões mascaradas

O modelo não vê a expressão da regra, para não decorá-la.

3 Regressão logística

Palavras ao redor, tipo e termo da entidade, posição no relato e fase dos vizinhos.

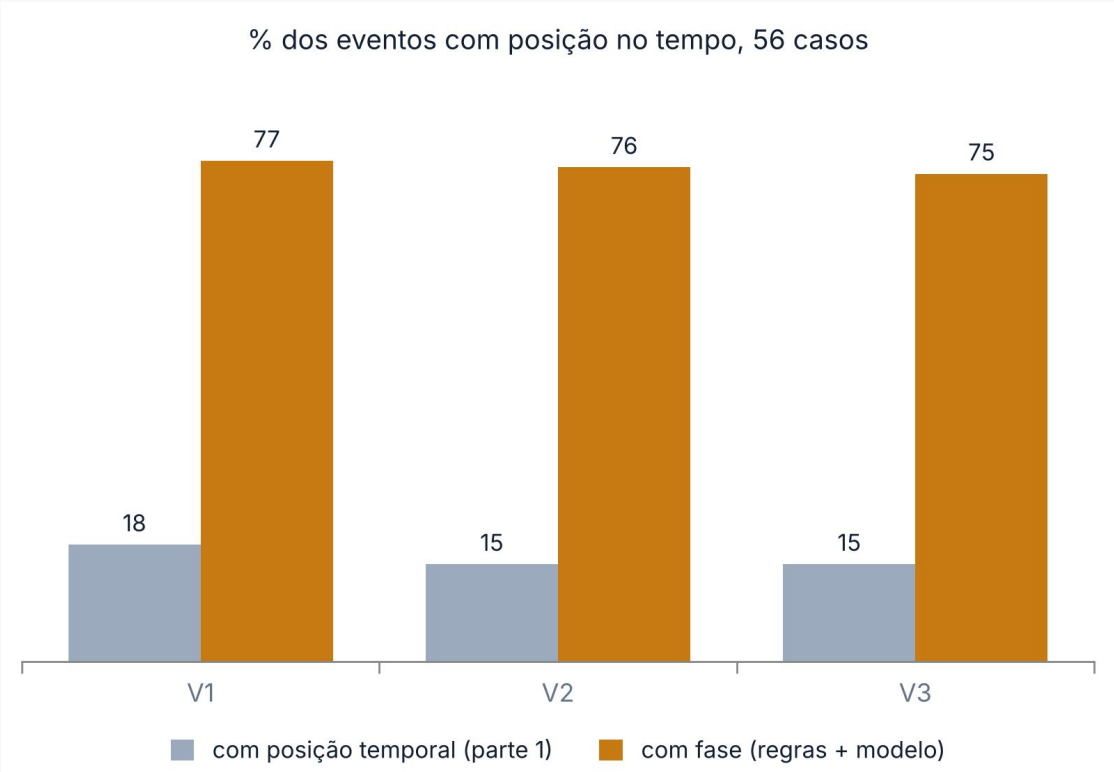
4 Fase aprendida

Eventos sem regra recebem a fase prevista quando o score ≥ 0,5.

Mesma ideia da V3: as regras da parte 1 viram rótulos, e os casos de avaliação ficam fora do treino.

FRENTE 3 · RESULTADOS

O modelo quase dobra a cobertura



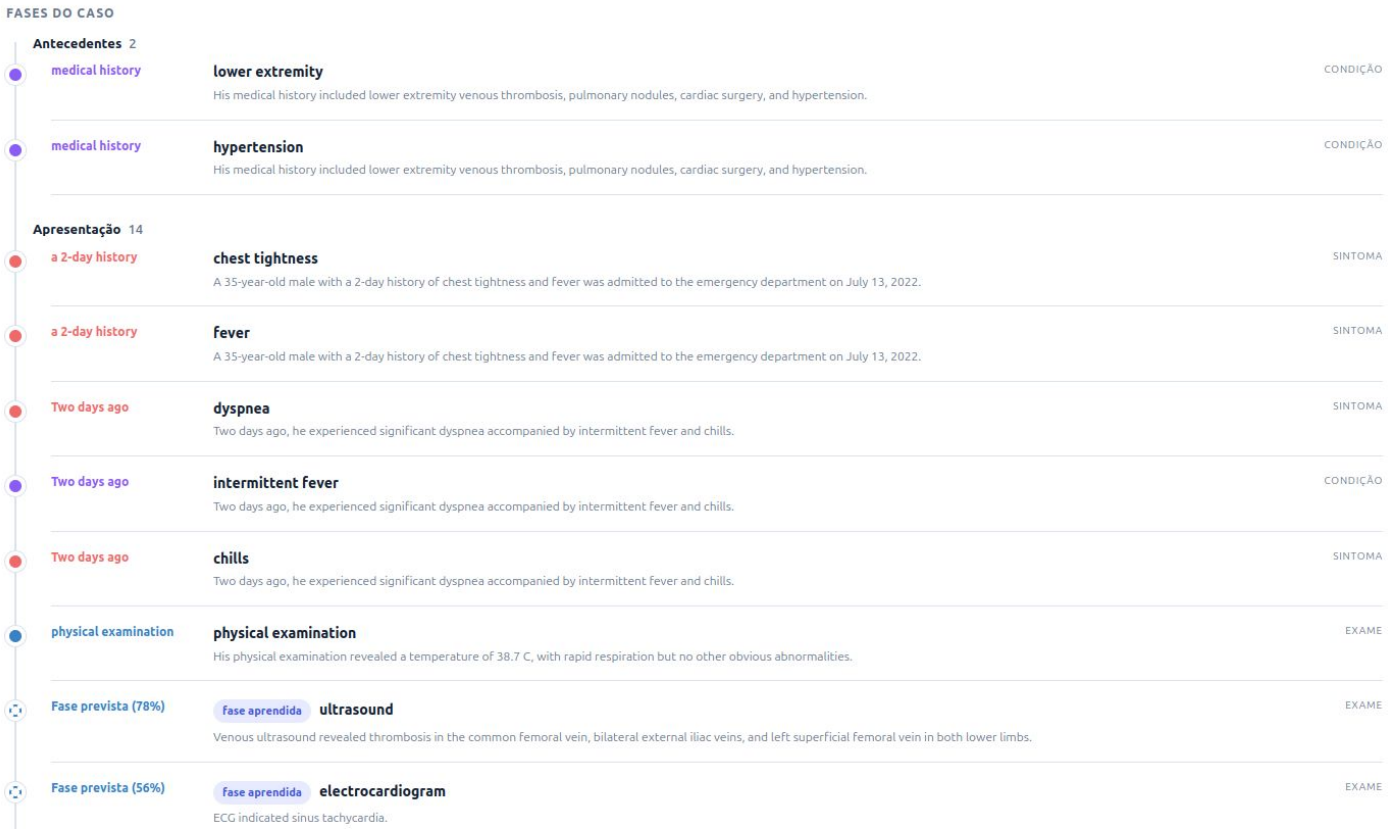
ACURÁCIA CONTRA A ANOTAÇÃO · 108 EVENTOS DOS 11 CASOS (V3)

Método	Cobertura	Acurácia
regras	39%	**0,805**
modelo, eventos sem regra	36%	0,744
regras + modelo	**75%**	**0,775**
tudo em "investigação"	100%	0,426

Pista mais forte
a fase dos vizinhos: o relato anda em ordem

Erro mais comum
readmissão posterior lida como apresentação

A linha do tempo agora é contada por fase



NA PÁGINA DE COMPARAÇÃO

Aba “Sequência de eventos”: eventos agrupados por fase; dentro de cada fase, as expressões de tempo e as BEFORE ordenam.

Marca “fase aprendida”: eventos que só o modelo posicionou, com o score.

Borda tracejada no grafo: termos que vieram do léxico V3.

DEMONSTRAÇÃO

https://lucasboaro.github.io/MC896---NLP/fase2/outputs/explorador.html?v=v3

caso PMC11368112_01, V3

HONESTIDADE EXPERIMENTAL

Limitações

Corpus pequeno

45 casos de mineração (V3), cerca de 28 mil palavras; 92 dos 145 termos da V2 aparecem uma única vez. Na V3+ (1.045 casos) a cobertura sobe, mas entra ruído.

Referências aproximadas

A V2 foi montada depois de ler os 11 casos, 11 relações da V3+ revisadas à mão: 8 corretas

Poucos rótulos

97 pares de relação e 108 eventos, cada conjunto com um único anotador. Diferenças de poucos centésimos não são confiáveis.

Fase não é ordem

A fase diz em que parte do relato o evento está, mas não o dia nem a ordem dentro da fase: as BEFORE continuam poucas.

Ainda fora do grafo: Na V3+, o Naive Bayes já cria TREATS e INDICATES no grafo. Os gatilhos aprendidos por PMI ainda precisam de revisão antes de entrar num triggers.csv

CONCLUSÃO

O que a parte 2 acrescentou à parte 1

A parte 1 entregou um extrator interpretável. A parte 2 o usou como plataforma para medir o que dá para aprender do próprio texto.

01

Léxico: modelo aprende, mas falta texto

O Com 45 casos a revocação não passou da V1; com 1.045, o léxico vai de 483 a 942 termos

02

Relações: ML onde as regras falham

Com rótulos reais, Naive Bayes recuperam relações que os gatilhos manuais perdiam.

03

Linha do tempo: de 15% para 75%

A fase aprendida posiciona o dobro dos eventos, com acurácia próxima à das regras (0,775 contra 0,805).

Continuação: revisão do grupo da anotação de fases e dos gatilhos PMI; filtro de ruído no léxico (fabricantes, siglas); usar a fase prevista para ordenar eventos (BEFORE)

DEMONSTRAÇÃO
lucasboaro.github.io/MC896---NLP/ · github.com/lucasBoaro/MC896---NLP